

CardioCare: 심장질환 예측 및 모니터링 시스템


1. 문제 정의와 사용 목적

심혈관 질환은 전 세계적으로 주요 사망 원인 중 하나이며, 조기 발견과 신속한 대응이 매우 중요하다. 그러나 실제 의료 현장에서는 다양한 임상 정보를 종합적으로 분석해야 하기 때문에 의료진의 부담이 크다.

본 프로젝트의 목표는 환자의 임상 정보를 기반으로 심장질환 위험 여부를 예측하는 머신러닝 모델을 개발하는 것이다. 이를 통해 의료진이 환자의 상태를 보다 빠르게 파악할 수 있도록 지원한다.

본 시스템은 "Inform, Not Decide" 원칙을 따른다. 즉, 모델은 의료진에게 참고 정보를 제공할 뿐이며 최종 진단 및 치료 결정은 반드시 의료 전문가가 수행한다. 따라서 본 시스템은 의사결정 지원 도구(Decision Support System)로 활용되는 것을 목적으로 한다.

2. EDA 핵심 결과



EDA를 통해 데이터의 클래스 분포, 이상치 존재 여부, 모델 비교 결과를 확인하였다. 분석 결과는 전처리 및 모델 선택의 근거로 활용되었다.

주요 결과

클래스 분포

질환군(1)은 508명, 비질환군(0)은 410명으로 나타났다. 클래스가 완전히 균형적이지 않으므로 Accuracy 대신 Balanced Accuracy를 주요 평가 지표로 사용하였다.

이상치 분석

trestbps, chol, oldpeak 변수에서 IQR 범위를 벗어나는 이상치가 다수 발견되었다. 이상치는 모델 성능에 영향을 줄 수 있으므로 전처리 과정에서 데이터 정제와 임상 범위 검증을 수행하였다.

모델 비교

MLflow 실험 결과 SVC 모델이 가장 높은 Balanced Accuracy(0.8435)를 기록하였다. 의료 분야에서는 실제 환자를 놓치는 False Negative가 중요하므로 Recall을 고려하여 최종 모델로 SVC를 선택하였다.

3. EDA 결과에 근거한 전처리 결정

EDA 결과를 바탕으로 다음 전처리를 수행하였다.

결측치 처리

원본 데이터에는 '?' 형태의 결측값이 존재하였다. 이를 NaN으로 변환하고 적절한 데이터 타입으로 변환하였다.

수치형 데이터 정제

연속형 변수의 데이터 타입을 통일하고 이상치를 분석하였다.

특징 선택

Random Forest 기반 Feature Selection을 수행하여 중요도가 낮은 변수를 제거하였다.

데이터 분할

학습 데이터와 테스트 데이터를 8:2 비율로 분할하였다. 또한 Stratified Split을 사용하여 클래스 비율을 유지하였다.

4. MLflow 실험 기반 모델 비교 및 최종 선택

비교 모델

본 프로젝트에서는 다음 다섯 개 모델을 비교하였다.

- Logistic Regression
- SVC
- Random Forest
- KNN
- Tuned Random Forest

평가 지표

- Balanced Accuracy
- Precision
- Recall
- F1 Score

결과

모델	Balanced Accuracy	Precision	Recall	F1
Logistic Regression	0.809	0.838	0.814	0.826
SVC	0.843	0.876	0.833	0.854
Random Forest	0.789	0.802	0.833	0.817
KNN	0.780	0.804	0.804	0.804
Tuned RF	0.801	0.817	0.833	0.825

최종 모델 선정

최종 모델은 SVC로 선정하였다.

선정 이유는 다음과 같다.

- 가장 높은 Balanced Accuracy
- 높은 Precision
- 높은 Recall
- 안정적인 일반화 성능

특히 의료 분야에서는 실제 환자를 놓치는 False Negative를 최소화하는 것이 중요하므로 Recall을 중요하게 고려하였다.

5. 테스트와 패키징

테스트

프로젝트의 신뢰성을 확보하기 위해 unittest를 작성하였다.

테스트 대상은 다음과 같다.

- 데이터 전처리
- 특징 및 타겟 분리
- 모델 학습 파이프라인
- 예측 결과 생성

실행 결과는 다음과 같다.

Ran 4 tests in 0.290s
OK

모든 테스트를 통과하여 핵심 기능이 정상적으로 동작함을 확인하였다.

패키징

Docker를 이용하여 실행 환경을 패키징하였다.

Docker를 사용한 이유는 다음과 같다.

- 환경 의존성 제거
- 재현성 확보
- 배포 간소화

이를 통해 사용자는 동일한 Docker 이미지를 사용하여 동일한 결과를 얻을 수 있다.

6. 드리프트 결과 및 재학습 / 피드백 루프 계획

드리프트 탐지 결과

Kolmogorov-Smirnov Test를 사용하여 데이터 분포 변화를 측정하였다.

Feature	Drift Detected
trestbps	True
chol	True
oldpeak	True

성능 변화

Dataset	Balanced Accuracy
Original Test	0.8435
Drifted Test	0.8191

드리프트 발생 후 성능이 감소하는 것을 확인하였다.

재학습 전략

다음 절차에 따라 재학습을 수행한다.

1. 드리프트 탐지
2. 성능 저하 확인
3. 데이터 품질 검토
4. 전문가 승인
5. 재학습 수행
6. 검증 후 운영 반영

폭주하는 피드백 루프 위험

자동 재학습만 반복할 경우 잘못된 데이터가 지속적으로 학습될 수 있으며 성능이 오히려 악화될 수 있다.

예를 들어 데이터 수집 오류가 발생한 상태에서 자동 재학습이 반복되면 모델이 잘못된 패턴을 학습하게 된다.

Human-in-the-loop

이를 방지하기 위해 데이터 과학자 또는 의료 전문가가 반드시 재학습 과정에 개입하도록 설계하였다.

재학습 여부는 사람이 승인하며 신규 모델은 운영 반영 전에 검증 절차를 거친다.

7. 서빙 방식 선택

선택: Model-as-a-Service

본 프로젝트는 Model-as-a-Service 방식을 선택하였다.

지연 시간

심장질환 예측은 실시간 밀리초 단위 응답이 필요한 서비스가 아니다. 따라서 서버 기반 예측이 충분히 가능하다.

개인정보(PHI)

중앙 서버에서 접근 제어와 감사 로그를 관리할 수 있다.

업데이트

모델 업데이트 시 서버만 수정하면 되므로 유지보수가 용이하다.

On-Device를 선택하지 않은 이유

병원마다 별도 배포가 필요하며 모델 버전 관리가 어렵다.

따라서 본 프로젝트에서는 중앙 서버 기반 구조가 더 적합하다고 판단하였다.

8. 한계 및 윤리적 고려사항

한계

- UCI 데이터셋 규모가 제한적이다.
- 실제 병원 환경을 완전히 반영하지 못한다.
- 특정 국가 환자 데이터에 편향될 수 있다.
- 설명 가능성(XAI)이 충분하지 않다.

윤리적 고려사항

- AI는 최종 진단자가 아니다.
- 환자 개인정보 보호가 필수적이다.
- 예측 결과에 대한 설명 가능성이 필요하다.
- 편향으로 인한 차별을 최소화해야 한다.

추가로 1주가 더 주어진다면

다음 기능을 추가하고자 한다.

- SHAP 기반 설명가능성(XAI)
- REST API 배포
- 자동 재학습 파이프라인
- 추가 임상 데이터 확보
- 실시간 모니터링 대시보드 구축

결론

본 프로젝트에서는 심장질환 예측을 위한 End-to-End 머신러닝 시스템을 구축하였다. 데이터 수집, 전처리, 모델 비교, MLflow 실험 관리, Docker 패키징, 데이터 드리프트 모니터링까지 포함하여 실제 머신러닝 서비스 개발 과정을 재현하였다.

최종 모델인 SVC는 Balanced Accuracy 84.35%, Recall 83.33%를 달성하였으며, 드리프트 감지 및 Human-in-the-loop 기반 재학습 전략까지 포함하여 운영 환경을 고려한 머신러닝 프로젝트로 완성하였다.